

Contents

1	Rauschanalyse und Ableitung rauschbasierter Schwellwerte	1
1.1	Betroffener Code	1
1.2	Motivation und Problemstellung	2
1.3	Signalmodell und Annahmen	2
1.4	Statistische Grundlagen	3
1.5	Umsetzung im Code	3
1.6	Anwendung in der Vorlagen-Extraktion	4
1.7	Anwendung im Amplitudenfitting	5
1.8	Grenzen und offene Punkte	5
2	Peak-Erkennung und Vorlagen Positionierung	7
2.1	Betroffener Code	7
2.2	Motivation und Problemstellung	7
2.3	Isolierte Abgasfahnen	7
2.4	Vorlagen Positionierung	7
2.4.1	Problemstellung	7
2.4.2	Lösungsansatz	8
2.4.3	Signalmodell und Zielfunktion	8
2.4.4	Koordinatenabstieg	8
2.4.5	Rauschkalibriertes Akzeptanzkriterium	9
2.4.6	Vorfilter über eine untere Schranke der SSE	9
	Bibliography	11

CHAPTER 1

Rauschanalyse und Ableitung rauschbasierter Schwellwerte

1.1 Betroffener Code

Stand Commit: XXXXXXXX

Table 1.1: Funktionen der Rauschanalyse, gruppiert nach Modul

Funktion	Rolle
<i>shared_services</i>	
<code>estimate_noise</code>	Median und $\hat{\sigma}$ nach (1.4), (1.5)
<code>influence_mask</code>	Approximation von T_0
<i>extraction_quality</i>	
<code>resolve_qa_thresholds</code>	Auflösung der Extraktions-Schwellwerte
<code>tail_rise_statistic</code>	Wiederanstiegsstatistik S
<code>_tail_threshold</code>	Kalibrierung nach (1.8)
<i>mode_l_fitting</i>	
<code>fit_day</code>	Noise Band und Ankerläufe
<code>refine_positions</code>	Akzeptanzschwelle ΔSSE

Table 1.2: Parameter, die in diesem Dokument hergeleitet werden

Parameter	Konfiguration	Default	Symbol
<code>peak_above_bg_sigma</code>	<code>ChannelQAConfig</code>	3,0	k_1 in (1.6)
<code>prominence_floor_sigma</code>	<code>ChannelQAConfig</code>	3,0	k_2 in (1.7)
<code>tail_percentile</code>	<code>ChannelQAConfig</code>	95	p in (1.8)
<code>noise_band_sigma</code>	<code>ModelConfig</code>	3,0	k_3 in (1.9)
<code>refine_min_dsse</code>	<code>ModelConfig</code>	8,0	κ in (2.4)
<code>min_anchor_run</code>	<code>ModelConfig</code>	5 s	l
<code>MAD_TO_SIGMA</code>	Konstante	1,4826	c in (1.5)

1.2 Motivation und Problemstellung

Die Erstellung repräsentativer Abgasprofile erfordert Qualitätskriterien, die jede isolierte Abgasfahne vor der Mittelung zu einer Vorlage erfüllen muss. Der *plume_template_extraction*-Algorithmus prüft die Daten hierzu auf Fehllaufzeichnungen, anomale Signalverläufe sowie unzureichende Signalstärken. Während Fehllaufzeichnungen wie Sensorausfälle über einen bewusst händisch gesetzten Minimalwert erkannt werden, den das Signal über eine Mindestdauer zusammenhängend unterschreiten muss, orientieren sich die Schwellwerte der übrigen Prüfungen an der Stärke des Messrauschens. Als Grundlage für deren einheitliche und kanalunabhängige Definition dient die im Folgenden beschriebene Rauschanalyse. Detektionsrelevante Parameter werden dabei als Vielfaches der Rauschstandardabweichung σ ausgedrückt. Der Fitter nutzt die Rauschanalyse für Anker-Detektion und Positionsverfeinerung.

1.3 Signalmodell und Annahmen

Das über „Point Sampling“ aufgezeichnete Konzentrationssignal eines Messkanals $x(t)$ setzt sich aus einem langsam driftenden Hintergrund $b(t)$, Messrauschen $\varepsilon(t)$ und den transienten Abgasfahnen $p_j(t)$ der passierenden Fahrzeuge j zusammen. Die in (1.1) gezeigte Signalzerlegung folgt der in [1] etablierten Sicht auf das Messsignal als Überlagerung von Fahrzeugemissionen und Hintergrund, erweitert sie jedoch um den Rauschterm $\varepsilon(t)$.

$$x(t) = b(t) + \varepsilon(t) + \sum_j p_j(t) \quad (1.1)$$

Der Begriff „Messsegment“ wird im Folgenden für einen zusammenhängend aufgezeichneten und gemeinsam verarbeiteten Datensatz verwendet. In der betrachteten Messkampagne (CARES-Milan [1]) entspricht ein Messsegment einem Messtag. Passagezeiten werden unabhängig vom Konzentrationssignal über eine Lichtschranke erfasst. Zwischen Durchfahrten liefert das Konzentrationssignal die Nullmessung, gegen die Detektionsentscheidungen getroffen werden. Die Rauschanalyse erfolgt unter Annahme A1 bis Annahme A3.

Annahme A1:

Rauschen in fahrzeugfreien Phasen ist repräsentativ für das Rauschen während einer Abgasfahne und wird innerhalb eines Messsegments als stationäre Größe behandelt.

Annahme A2:

Die Lichtschranke erfasst jedes Fahrzeug j , welches den Messaufbau passiert.

Annahme A3:

Messrauschen beinhaltet alle Abweichungen vom driftenden Hintergrund $b(t)$, die nicht durch die Abgasfahne $p_j(t)$ einer erfassten Durchfahrt j verursacht wurden.

1.4 Statistische Grundlagen

Um eine hohe Robustheit gegenüber Ausreißern zu gewährleisten, die aufgrund der weit gefassten Definition in Annahme A3 zu erwarten sind, wird das Rauschen $\varepsilon(t)$ über die Median Absolute Deviation (MAD) geschätzt. Die Hintergrundschätzung $\hat{b}(t)$ erfolgt über das rollierende 2 %-Perzentil [vgl. 2, S. 11700]. Unter der Definition des allgemeinen Signalresiduums $r(t) = x(t) - \hat{b}(t)$ und der Menge der fahrzeugfreien Zeitpunkte

$$T_0 = \left\{ t \mid \sum_j p_j(t) = 0 \right\} \quad (1.2)$$

ergibt sich für das nach Annahme A2 fahrzeugfreie Signalresiduum $r_F(t)$:

$$r_F(t) = x(t)|_{T_0} - \hat{b}(t)|_{T_0} \quad (1.3)$$

Die MAD berechnet sich aus dem Median der absoluten Abweichung der Datenreihe von ihrem Median.

$$MAD = \text{median}(|r_F - \text{median}(r_F)|) \quad (1.4)$$

Da sich das Rauschen als Überlagerung vieler unabhängiger kleiner Störeinflüsse auffassen lässt, wird es unter Verweis auf den Zentralen Grenzwertsatz [vgl. 3, S. 324] als annähernd normalverteilt angenommen. Durch diese Annahme kann die MAD über die Konstante $c = 1/(\Phi^{-1}(\frac{3}{4})) \approx 1,4826$ als robuster Schätzer für die Standardabweichung $\hat{\sigma}$ verwendet werden [4].

$$\hat{\sigma} = c \cdot MAD = 1,4826 \cdot MAD \quad (1.5)$$

1.5 Umsetzung im Code

In der Umsetzung wird T_0 über feste Ausschlussfenster um jede erfasste Durchfahrt approximiert. Über das Fenster hinaus abklingende Fahnenreste zählen damit zum Rauschen, was $\hat{\sigma}$ konservativ überschätzt. Das Ausschlussfenster wird mit *window_before* und *window_after*

um jede erfasste Durchfahrt gelegt, hierbei ist *window_after* generell größer zu wählen, da es die gesamte Ankunfts- und Abfallzeit der Abgasfahnen beinhalten muss. Im Fitting wird die *influence_mask* über dasselbe Konstrukt gebaut, die Parametrisierung von *influence_before* und *influence_after* kann hierbei enger gewählt werden. Die Extraktion speichert für jede extrahierte Abgasfahne die Verzögerung zwischen Lichtschrankenpassage und aufkommen des Peaks, im Fitting wird das Fenster um die Durchfahrtszeit addiert mit der Medianverzögerung gelegt. Extraktion und Fitting können somit für das gleiche Messsegment aufgrund der T_0 Approximation leicht voneinander abweichende Schätzungen für $\hat{\sigma}$ liefern. Die Extraktion löst Schwellwerte einmal pro Kanal und Messsegment über die Funktion *resolve_qa_thresholds* auf.

1.6 Anwendung in der Vorlagen-Extraktion

Der Parameter *min_peak_above_bg* (1.6) entscheidet über die für Vorlagenbildung ausreichende Ausprägung einer isolierten Abgasfahne. Hierbei wird *min_peak_above_bg* als Vielfaches k von $\hat{\sigma}$ über dem Rauschmedian $\text{median}(r_F)$ definiert.

$$\text{min_peak_above_bg} = \text{median}(r_F) + k_1 \cdot \hat{\sigma} \quad (1.6)$$

Ein weiterer Parameter bezüglich der Prominenz eines Abgaspeaks ist *min_prominence_floor* (1.7). Er bildet die untere Schranke der Prominenzschwelle in der Mehrfachpeak-Erkennung und verhindert damit, dass reine Rauschpeaks als eigenständige Peaks interpretiert werden. Die eigentliche Relativprüfung gegenüber der Höhe des Hauptpeaks erfolgt über den separat beschriebenen Parameter *min_prominence_ratio*, wobei von beiden Schwellen stets die größere greift. Definiert ist *min_prominence_floor* als Vielfaches k von $\hat{\sigma}$. Da die Prominenz eine relative Größe zwischen Peak und Umgebung ist, entfällt der Rauschmedian Offset.

$$\text{min_prominence_floor} = k_2 \cdot \hat{\sigma} \quad (1.7)$$

Die Analyse von anomalen Signalverläufen beschränkt sich auf das Abklingverhalten der Abgasfahnen. Gemäß [2, S. 11700] geht das mittlere Abgasfahnenprofil nach einem steilen Anstieg in einen exponentiellen Abfall über, dieser Abfall wird auf Monotonie überprüft. Ziel der Überprüfung ist es anomale Abfälle zu markieren, welche mit entsprechender Konfidenz nicht rein auf Signalrauschen rückführbar sind. Die Ableitung dieser Parameter beruht stark auf der Annahme A1.

Die Variable *window_after_peak* definiert den erwarteten Zeitraum des Signalabfalls. Hierzu wird das fahrzeugfreie Signalresiduum $r_F(t)$ in m Segmente der Länge *window_after_peak* aufgeteilt. Diese Segmente werden mit einem gleitenden Mittelwert [vgl. 3, S. 567] geglättet und dann der kumulative Anstieg S_m im Segment berechnet. Das Resultat ist eine empirische Verteilung der Wiederanstiege, die der Kanal in fahrzeugfreien Abschnitten des betrachteten Messsegments aufweist. Die Abfallflanke *tail* der zu überprüfenden Abgasfahne durchläuft dieselbe Glättung wie die Referenzsegmente m .

Der QA-Parameter $p = \text{tail_percentile}$ legt die Strenge des Kriteriums kanalunabhängig als Perzentil der ermittelten Verteilung $\{S_m\}$ fest.

$$\text{TAIL_ANOMALY} \iff S(\text{tail}) > T \text{ mit } T = Q_p(\{S_m\}) \quad (1.8)$$

Es handelt sich somit um einen anomalen Signalverlauf, wenn der kumulative Wiederanstieg der Abfallflanke den Wert überschreitet, unter dem das Rauschen in $\text{tail_percentile} \%$ der fahrzeugfreien Abschnitte bleibt.

1.7 Anwendung im Amplitudenfitting

Die Rauschanalyse wird im Fitting für das Finden von Ankerpunkten verwendet. Ankerpunkte bezeichnen hierbei Samples, die frei von Fahrzeugeinfluss sind und deren Amplitude sich in einem definierten Rauschband (1.9) befindet. Ein Ankerlauf ist hierbei als Zeitraum l definiert, indem jedes Sample ein Ankerpunkt ist. Diese Ankerläufe werden zur Separierung des Messsegments in Teilsegmente und als Bezugspunkte für den Baseline Fit genutzt. Innerhalb eines Teilsegments sind passierende Fahrzeuge Teil eines Fit-Problems. Ein Sample gilt als Ankerpunkt, wenn es die Bedingung (1.9) erfüllt.

$$t \in T_0 \cap |r(t) - \text{median}(r_F)| < k_3 \cdot \hat{\sigma} \quad (1.9)$$

Das Fitting implementiert eine Logik zur Verfeinerung der Positionierung der Vorlagen. Vorlagen werden initial in der Designmatrix basierend auf Lichtschränken und Medianverzögerung platziert. Eine Falschplatzierung in der Designmatrix führt zu einem systematischen Fehler, der sich in der Summe der quadrierten Residuen (SSE) des Fits widerspiegelt. Wird das Template nun um die initiale Position verschoben ändert sich die SSE um ΔSSE . Diese Änderung wird ausgewertet und gibt Auskunft über die Korrektheit der Positionierung. Hierbei wird die Schwelle ΔSSE welche eine Umplatzierung des Templates rechtfertigt aus dem Messrauschen abgeleitet.

$$\Delta\text{SSE}_i(p) = \text{SSE}(\tau) - \text{SSE}(\tau | \tau_i \rightarrow p) > \kappa \hat{\sigma}^2 \quad (1.10)$$

Da es sich bei der SSE um eine Summe der Quadrate handelt, muss auch $\hat{\sigma}$ für die Schranke quadriert werden. Der Standardwert $\kappa = 8$ basiert auf Beobachtungen und ist so zu wählen, dass schwache Abgasfahnen die Möglichkeit bekommen ihre Position zu verfeinern jedoch nicht Rausch bestimmt wandern.

1.8 Grenzen und offene Punkte

CHAPTER 2

Peak-Erkennung und Vorlagen Positionierung

2.1 Betroffener Code

2.2 Motivation und Problemstellung

Im Point Sampling Aufbau [vgl. 1, S. 2483] werden Fahrzeugdurchfahrten mithilfe einer Lichtschranke erfasst. Der Erfassungszeitpunkt wird im Folgenden als „LB-Trigger“ bezeichnet. Da zwischen dem LB-Trigger und der Erfassung des fahrzeugspezifischen Abgaspeaks eine Verzögerungszeit liegt, die zwischen Durchfahrten aufgrund von unter anderem Transportweg von Auspuff zu Messaufbau, Geschwindigkeit und Fahrzeuggeometrie variiert, würde eine direkte zeitliche Gleichsetzung von Trigger und erwarteten Peak zu einem nicht vernachlässigbaren Fehler in der Auswertung führen. Folglich darf die Lichtschranke nur zur groben Positionsabschätzung der Abgasfahne und für die Zuordnung der Fahrzeugreihenfolge verwendet werden. Die exakte Position der Abgaspeaks muss stattdessen direkt aus den Messdaten abgeleitet werden, die Komplexität dieser Ableitung variiert stark basierend auf der Dichte an Durchfahrten in einem Segment. Für isolierte Abgasfahnen, die für die Vorlagenextraktion genutzt werden, ist ein einfacher Algorithmus zur Peak-Erkennung ausreichend. Bei überlappenden Durchfahrten mit verwaschenen Einzelpeaks werden stattdessen die extrahierten Vorlagen als Referenz zur Positionierung herangezogen.

2.3 Isolierte Abgasfahnen

2.4 Vorlagen Positionierung

2.4.1 Problemstellung

Im PlumeFit Ansatz wird ein Messsegment in mehrere Teilsegmente begrenzt durch fahrzeugfreie Bereiche aufgeteilt. Innerhalb eines Teilsegments sind passierende Fahrzeuge Teil eines

Fit-Problems. Jedes Fahrzeug erhält in der Designmatrix eine Spalte mit der dazugehörigen Vorlage platziert auf der erwarteten Peak Position basierend auf der mittleren Verzögerung zwischen LB-Trigger und Abgaspeak. Diese mittlere Verzögerung wird in der Erstellung der Vorlagen erfasst. Die Verzögerungszeit zwischen LB-Trigger und Abgaspeak ist, jedoch durchfahrtspezifisch und eine Falschplatzierung der Vorlagen führt zu einer systematischen Unterschätzung der Abgasfahne.

2.4.2 Lösungsansatz

Da es sich bei einem Teilsegment um ein isoliertes Fit-Problem handelt, kann dieses über die Summe der quadrierten Residuen (SSE) bewertet werden. Eine falsch platzierte Vorlage erklärt das Signal unvollständig, wodurch die SSE steigt. Die Position kann folglich durch gezieltes Verschieben der Vorlagen und Neuauswertung optimiert werden. Die Positionierung nutzt somit die gesamte Vorlagenform statt eines einzelnen Maximums.

2.4.3 Signalmodell und Zielfunktion

Es wird ein Teilsegment mit n Samples, k Durchfahrten indiziert mit j und dem hintergrundbereinigten Signal $y(t)$ betrachtet. Die Designmatrix $\mathbf{A}(\tau)$ enthält für jede Durchfahrt eine Vorlagenspalte $s_j(\tau_j)$ mit Peak auf der Position τ_j sowie die Baselinespalten mit den Koeffizienten β . Der in Mode-L-Fit verwendete Bounded-variable least squares (BVLS) [5] liefert für feste Positionen, die $SSE(\tau)$ nach:

$$SSE(\tau) = \min_{\mathbf{a} \geq 0, \beta} \left\| \mathbf{y} - \mathbf{A}(\tau) \begin{bmatrix} \mathbf{a} \\ \beta \end{bmatrix} \right\|^2 \quad (2.1)$$

Die Positionsschätzung ist somit:

$$\hat{\tau} = \arg \min_{\tau} SSE(\tau), \quad \tau_j \in [\ell_j, h_j]. \quad (2.2)$$

Das Band $[\ell_j, h_j]$ legt das Sample-Fenster fest, indem eine Vorlage um seine Initialposition verschoben werden darf. Im Code wird ebenfalls auf Segmentgrenzen geprüft. Die exakte Lösung von (2.2) wäre (2.1) für alle möglichen Positionskombinationen. Diese Lösung ist aber extrem rechenintensiv, bei W Kandidatenpositionen je Durchfahrt müssten W^k BVLS-Fits pro Segment durchgeführt werden. Der implementierte *refine_positions* Algorithmus löst das Problem deshalb nur näherungsweise. Statt einer gemeinsamen Positionsoptimierung wird ein zyklischer Koordinatenabstieg [6], der die Positionen nacheinander optimiert genutzt. Ein Vorfilter, der je Durchfahrt die Kandidaten über eine untere Schranke der SSE aussortiert optimiert die Laufzeit durch Reduktion der BVLS-Fits. Eine Verschiebung wird nur dann akzeptiert, wenn die Verbesserung, der SSE nicht rein durch Rauschen erklärbar ist.

2.4.4 Koordinatenabstieg

Vor dem Koordinatenabstieg wird mit den initialen Positionen der Vorlagen ein Referenz BVLS-Fit durchgeführt, dieser Fit liefert die zu Verbessende SSE und die Anfangsamplituden

der Vorlagen. Der Koordinatenabstieg erfolgt von größter zu kleinster Initialamplitude, dies soll schwache Durchfahrten davon abhalten, in die Flanken stärkerer Nachbarn zu wandern, was zu einer Überschätzung der schwachen und Unterschätzung der starken Abgasfahne führen würde. Es wird jeweils eine Durchfahrt j betrachtet, die Positionen der übrigen Durchfahrten werden festgehalten. Die Variable p beschreibt einen Positionskandidaten der aktuell betrachteten Durchfahrt j . Positionskandidaten sind mögliche Verschiebungen im Suchband $[\ell_j, h_j]$. Der Ausdruck in (2.3) beschreibt folglich, dass die Vorlage genauer gesagt die Peak Position der Durchfahrt j auf die Position des Kandidaten p gesetzt wird welche die SSE des Fits minimiert, wenn alle anderen Durchfahrten festgehalten werden.

$$\tau_j \leftarrow \arg \min_{p \in [\ell_j, h_j]} \text{SSE}(\tau \mid \tau_j \rightarrow p) \quad (2.3)$$

Die Optimierung aus (2.3) wird pro Durchlauf der Positionsverfeinerung einmal auf alle Durchfahrten angewandt. Die maximale Anzahl der Verfeinerungsdurchläufe kann über *refine_sweeps* angepasst werden, die Optimierung bricht aber automatisch ab, sobald ein Durchlauf keine Position mehr verfeinert. Das Ergebnis ist ein lokales Optimum von (2.1), keine einzelne Durchfahrt kann die SSE durch eine Verschiebung innerhalb der erlaubten Grenzen weiter senken.

2.4.5 Rauschkalibriertes Akzeptanzkriterium

Auf verrauschten Daten senkt fast jede Verschiebung die SSE geringfügig, dies trifft hauptsächlich bei Durchfahrten mit schwacher initial Amplitude zu. Um zu verhindern, dass Vorlagen basierend auf Rauschen verschoben werden wird eine Verschiebung nur dann akzeptiert, wenn

$$\Delta \text{SSE}_j(p) = \text{SSE}(\tau) - \text{SSE}(\tau \mid \tau_j \rightarrow p) > \kappa \hat{\sigma}^2, \quad \kappa = 8 \quad (2.4)$$

gilt.

2.4.6 Vorfilter über eine untere Schranke der SSE

Der Vorfilter wird verwendet, um die benötigte Anzahl an BVLS-Fits weiter zu reduzieren. Lässt man die Amplitudenbeschränkung weg reduziert sich das Problem zu einem „Ordinary Least Squares“, da dieser über eine größere Menge minimiert kann das Minimum dieser Optimierung nie größer sein als das der BVLS Minimierung, es handelt sich also um eine untere Schranke der SSE. Der Filter bezieht sich hauptsächlich auf die Änderung der SSE beim Hinzufügen einer Spalte in die Designmatrix [7, Thm. 3.5].

$$\text{SSE}_{\text{OLS}}(p) \leq \text{SSE}_{\text{BVLS}}(p) \quad (2.5)$$

Die SSE der ungebundenen Optimierung besitzt eine geschlossene Form, die sich effizient über eine Regression für alle Positionskandidaten einer Durchfahrt auf einmal berechnen lässt.

Hierbei ist A_{-j} die Designmatrix ohne der aktuell zu betrachtenden Durchfahrt j . Die Vorlagenspalte der Durchfahrt j wird mit $s(p)$ mit Peak am Positionskandidaten p beschrieben. M wird als Residualisierungs-Operator [7, 3.2.4] mit:

$$M = I - A_{-j}A_{-j}^+, \quad A_{-j}^+ = (A_{-j}^\top A_{-j})^{-1} A_{-j}^\top. \quad (2.6)$$

Nach [7, 3.2.4] gilt mit $e = My$:

$$y_\perp := My = y - A_{-j}\hat{c}_y, \quad s_\perp(p) := Ms(p) = s(p) - A_{-j}\hat{c}_s \quad (2.7)$$

$y_\perp$ ($y_{\perp\text{perp}}$) ist somit der Anteil des Signals, den die Nachbarn der entfernten Durchfahrt und die Baseline nicht erklären und $s_\perp(p)$ ($s_{\perp\text{perp}}$) ist analog dazu der Anteil der Kandidatenspalte $s(p)$, den die Nachbarn und die Baseline nicht darstellen können. In [7, Thm. 3.5] entspricht $s_\perp(p)$ dem Vektor z_* . (2.7) kann für alle Kandidaten über einen einzigen *np.linalg.lstsq* Aufruf berechnet werden, da M nur von A_{-j} abhängt. Die SSE der Regression von y auf A_{-j} ergibt sich zu:

$$sse_without = \|y_\perp\|^2 \quad (2.8)$$

Zur Betrachtung wie sich, die SSE bei Einbringen der Kandidaten ändert, wird [7, Thm. 3.5] betrachtet. Hierbei gilt $\mathbf{e}'\mathbf{e} = \|y_\perp\|^2$, $\mathbf{y}_* = \mathbf{y}_\perp$ und $\mathbf{z}_* = s_\perp(p) = \mathbf{s}_\perp$ das Ziel der Berechnung ist es $\mathbf{u}'\mathbf{u} = SSE_{OLS}(p)$ zu erhalten.

$$\mathbf{u}'\mathbf{u} = \mathbf{e}'\mathbf{e} - c^2(\mathbf{z}_*'\mathbf{z}_*) \leq \mathbf{e}'\mathbf{e} \quad (2.9)$$

für $c^2(\mathbf{z}_*'\mathbf{z}_*)$ gilt nach [7, S. 30]:

$$c^2(\mathbf{z}_*'\mathbf{z}_*) = \frac{(\mathbf{z}_*'\mathbf{y}_*)^2}{\mathbf{z}_*'\mathbf{z}_*} \quad (2.10)$$

dadurch ergibt sich für $SSE_{OLS}(p)$:

$$SSE_{OLS}(p) = \|y_\perp\|^2 - \frac{(\mathbf{s}_\perp^T \mathbf{y}_\perp)^2}{\|\mathbf{s}_\perp\|^2} = sse_without - \frac{num^2}{denom} \quad (2.11)$$

Da (2.1) $a_j \geq 0$ verlangt, wird im Code der SSE Gewinn nur dann angerechnet, wenn $\mathbf{s}_\perp^T \mathbf{y}_\perp > 0$ also die Vorlage, die SSE mit positiver Amplitude verbessern kann. Die Kandidaten werden in Reihenfolge der höchsten Verbesserung in der unteren Schranke durchlaufen und der Gewinn wird mittels BVLS-Fit validiert.

Bibliography

- [1] M. Knoll, M. Penz, H. Juchem, C. Schmidt, D. Pöhler, and A. Bergmann, “Large-scale automated emission measurement of individual vehicles with point sampling,” *Atmospheric Measurement Techniques*, vol. 17, no. 8, pp. 2481–2505, Apr. 2024. [Online]. Available: <https://amt.copernicus.org/articles/17/2481/2024/> → [p2], [p7]
- [2] N. J. Farren, M. Knoll, A. Bergmann, R. L. Wagner, M. D. Shaw, S. Wilson, Y. Bernard, and D. C. Carslaw, “Highly Disaggregated Particulate and Gaseous Vehicle Emission Factors and Ambient Concentration Apportionment Using a Plume Regression Technique,” *Environmental Science & Technology*, vol. 59, no. 23, pp. 11 698–11 707, Jun. 2025. [Online]. Available: <https://doi.org/10.1021/acs.est.5c05015> → [p3], [p4]
- [3] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot, and G. Tutz, *Statistik: Der Weg zur Datenanalyse*, 9th ed. Berlin, Heidelberg: Springer Berlin Heidelberg, 2024. → [p3], [p4]
- [4] C. Leys, C. Ley, O. Klein, P. Bernard, and L. Licata, “Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median,” *Journal of Experimental Social Psychology*, vol. 49, no. 4, pp. 764–766, Jul. 2013. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0022103113000668> → [p3]
- [5] P. Stark and R. Parker, “Bounded-Variable Least-Squares: an Algorithm and Applications,” *Computational Statistics*, vol. 10, Jan. 1995. → [p8]
- [6] S. J. Wright, “Coordinate descent algorithms,” *Mathematical Programming*, vol. 151, no. 1, pp. 3–34, Jun. 2015. [Online]. Available: <https://doi.org/10.1007/s10107-015-0892-3> → [p8]
- [7] W. H. Greene, *Econometric Analysis*. Prentice Hall, 2003, google-Books-ID: 7i9lQgAACAAJ. → [p9], [p10]